[SLIDES: LLM-305: LLMS E INTELIGENCIA ARTIFICIAL GENERATIVA - PAGINA 1]
AVISO: MATERIAL DIDATICO EXPERIMENTAL DE DESENVOLVIMENTO AGUARDANDO HOMOLOGACAO INSTITUCIONAL
Este conteudo destina-se a validacao tecnica da plataforma e nao substitui apostilas oficialmente aprovadas pela instituicao.
LAMINA DIDATICA 1: SECAO 1: ARQUITETURA TRANSFORMER E MECANISMOS DE AUTO-ATENCAO
SINTESE CONCEITUAL E DIAGRAMAS:
A revolucao dos Large Language Models baseia-se no mecanismo de auto-atencao escalonada (Scaled Dot-Product Attention) introduzido por Vaswani et al. (2017). Projecoes lineares geram tensores de Consulta (Q), Chave (K) e Valor (V). A formula Attention(Q,K,V) = softmax(QK^T / sqrt(d_k)) V permite que cada token pondere semanticamente todos os demais tokens da sequencia simultaneamente, superando os gargalos sequenciais de RNNs.

[SLIDES: LLM-305: LLMS E INTELIGENCIA ARTIFICIAL GENERATIVA - PAGINA 2]
AVISO: MATERIAL DIDATICO EXPERIMENTAL DE DESENVOLVIMENTO
AGUARDANDO HOMOLOGACAO INSTITUCIONAL
Este conteudo destina-se a validacao tecnica da plataforma e nao substitui
apostilas oficialmente aprovadas pela instituicao.
LAMINA DIDATICA 2: SECAO 2: ENGENHARIA DE PROMPTS AVANCADA E RESPOSTAS
ESTRUTURADAS
SINTESE CONCEITUAL E DIAGRAMAS:
Tecnicas como Few-Shot Prompting fornecem demonstracoes exemplares no
proprio prompt de entrada; Chain-of-Thought (CoT) induz raciocinio
explicito passo a passo antes da resposta final. A especificacao de schemas
estruturados (JSON Mode / Structured Outputs) instrui a camada de
amostragem do modelo a emitir exclusivamente dados aderentes a contratos
estritos de tipos.

[SLIDES: LLM-305: LLMS E INTELIGENCIA ARTIFICIAL GENERATIVA - PAGINA 3]
AVISO: MATERIAL DIDATICO EXPERIMENTAL DE DESENVOLVIMENTO
AGUARDANDO HOMOLOGACAO INSTITUCIONAL
Este conteudo destina-se a validacao tecnica da plataforma e nao substitui
apostilas oficialmente aprovadas pela instituicao.
LAMINA DIDATICA 3: SECAO 3: ARQUITETURA RAG COMPLETA: CHUNKING, EMBEDDINGS
E RERANKING
SINTESE CONCEITUAL E DIAGRAMAS:
RAG (Retrieval-Augmented Generation) ancora geracoes em bases confiaveis de
conhecimento proprio. O processo abrange: 1. Chunking semantico de
documentos com sobreposicao (overlap); 2. Geracao de vetores densos via
modelos de embedding; 3. Busca de k-vizinhos mais proximos por similaridade
de cosseno; 4. Reordenacao (Reranking) contextual; 5. Insercao dos trechos
citados no prompt do modelo gerador.

[SLIDES: LLM-305: LLMS E INTELIGENCIA ARTIFICIAL GENERATIVA - PAGINA 4]
AVISO: MATERIAL DIDATICO EXPERIMENTAL DE DESENVOLVIMENTO
AGUARDANDO HOMOLOGACAO INSTITUCIONAL
Este conteudo destina-se a validacao tecnica da plataforma e nao substitui
apostilas oficialmente aprovadas pela instituicao.
LAMINA DIDATICA 4: SECAO 4: INTEGRACAO COM O SDK @GOOGLE/GENAI E GEMINI 3.8 FLASH
SINTESE CONCEITUAL E DIAGRAMAS:
O SDK oficial @google/genai fornece acesso a modelos de ultima geracao como
Gemini 3.8 Flash. A integracao deve implementar respostas em fluxo
(streaming), tratamento robusto de limites de cota (HTTP 429 com backoff
exponencial) e fallback resiliente (como indexacao lexica TF-IDF).
Atividade: Construir pipeline RAG ponta a ponta com recuperacao de trechos
e citacao transparente de fontes.